

# 구현 이슈 및 한계점 보고서

| 항목    | 내용                                    |
|-------|---------------------------------------|
| 프로젝트  | 집에서 언제 출발해야 따릉이를 탈 수 있을까?             |
| 평가 범위 | data/ , src/ , scripts/ , notebooks/  |
| 작성 목적 | 코드·Notebook 구현에서 드러나는 이슈를 한계점과 연결해 정리 |

## 1. 개요

본 보고서는 구현 산출물만을 기준으로, **관찰된 이슈** → **원인** → **프로젝트 한계**를 대응 관계로 기술한다. 각 한계는 “버그”와 “의도된 단순화”를 구분하며, 후자는 기말 과제 범위·데이터·연산 자원 제약에서 비롯된 설계 선택으로 해석한다.

## 전체 한계의 축 (요약)

| 축   | 내용                                |
|-----|-----------------------------------|
| 시간  | 2024년 과거 패턴으로 미래(실행 시점) 출발 시각을 추정 |
| 공간  | 200m 구역·구역 평균 가용 대수로 개별 대여소를 대표   |
| 데이터 | 3개월·샘플 학습, A↔B 조인 미매칭 제외          |
| 모델  | 시간·구역 위주 특성, 외부 요인(날씨·이벤트) 미반영    |
| 서비스 | 실시간 API 가용이 아닌 오프라인 학습·배치 예측      |

## 2. 데이터 수집 ( data/ )

### 2-1. 다수 수집·소수 사용

| 항목       | 내용                                                                                                                                    |
|----------|---------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | data/ 에 2024 가용량, 2025 대여소, 대여이력, 월별 이용, 2019~2021 구 데이터 등이 있으나, 파이프라인은 <b>2024 가용 3개월(2401/2404/2407) + 2025.12 대여소 XLSX</b> 만 사용한다. |
| 설명       | 대여이력(월 ~300MB)은 트립 단위라 “특정 시각 거치대수” 스냅샷이 아니며, 월별 이용정보는 시간 해상도가 부족하다. 코드상 AVAILABILITY_MONTHS , station_xlsx() 가 이 조합만 가리킨다.           |
| 연관<br>한계 | <b>데이터 범위 한계</b> ? 계절·요일 패턴은 1·4·7월 겨울·봄·여름 대표 샘플에 국한되며, 연말·휴일·이벤트 등은 학습·검증에 충분히 반영되지 않을 수 있다.                                        |
| 영향       | Notebook·예측 결과는 “서울 전체·연중”이 아니라 <b>선택된 3개월의 통계적 평균</b> 에 가깝다.                                                                         |

### 2-2. 시점 불일치 (2024 가용 + 2025 좌표)

| 항목       | 내용                                                                                                        |
|----------|-----------------------------------------------------------------------------------------------------------|
| 이슈       | 가용 수량은 2024년, 좌표·대여소 마스터는 2025.12 기준이다. norm_station_no 후 inner join으로 <b>매칭되지 않는 대여소 행은 ETL에서 제외</b> 된다. |
| 설명       | etl._process_chunk 는 station_keys 에 없는 station_no_norm 을 필터링한다. 2024에만 있거나 2025에 폐쇄된 대여소는 분석 대상에서 빠진다.    |
| 연관<br>한계 | <b>공간 커버리지 한계</b> ? 조인 실패 구간의 가용 패턴은 모델이 학습·예측하지 못한다. 구역 평균 ( bike_count_mean )은 남은 대여소만으로 집계된다.          |
| 영향       | 특히 신설·폐쇄가 많은 구역에서 예측과 실제 체감 가용성의 괴리가 커질 수 있다.                                                             |

### 2-3. 원본 Git 미포함

| 항목 | 내용                                                                          |
|----|-----------------------------------------------------------------------------|
| 이슈 | .gitignore 에 *.csv , *.xlsx 가 있어 원본 데이터는 저장소에 없고, data/processed/ 캐시에 의존한다. |

| 항목       | 내용                                                                                                 |
|----------|----------------------------------------------------------------------------------------------------|
| 설명       | 제출·재현 시 수동으로 공공데이터를 받아 동일 경로에 두거나, 이미 생성된 processed 파일이 있어야 한다.                                    |
| 연관<br>한계 | <b>재현성 한계</b> ? 환경은 requirements.txt 로 맞출 수 있으나, <b>동일 원본·동일 ETL</b> 을 보장하려면 데이터 수집 단계가 별도 전제가 된다. |

## 3. ETL·전처리 ( src/etl.py , src/stations.py )

### 3-1. 구역 단위 집계로 정보 손실

| 항목       | 내용                                                                                                                                  |
|----------|-------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | aggregate_zone_hour 가 (date, hour, cluster_id) 단위로 bike_count_mean , bike_count_max 를 산출하고, ML 타깃은 <b>평균( bike_count_mean )</b> 이다. |
| 설명       | 같은 구역 안에서도 대여소마다 거치 대수가 다르다. 평균은 “구역 어딘가에 자전거가 있다”는 느슨한 신호이며, 사용자가 도착하는 <b>최근접 대여소</b> 와 불일치할 수 있다.                                 |
| 연관<br>한계 | <b>공간 해상도 한계</b> ? 예측은 구역 패턴, 의사결정은 nearest_station 한 곳에 의존한다. 구역 평균 3대여도 최근접 대여소가 0대일 수 있다(코드는 구역 모델만 사용).                         |
| 영향       | predict_origin_rental 의 가용 판정이 <b>실제 대여 가능성을 과대·과소 추정</b> 할 수 있다.                                                                   |

### 3-2. 청크 ETL과 메모리·완전성

| 항목       | 내용                                                                                                                |
|----------|-------------------------------------------------------------------------------------------------------------------|
| 이슈       | 월별 chunksize=100_000 처리 후 pd.concat 으로 합친 뒤 availability_station_hour.csv 전체를 저장한다. 3개월 합산 시 <b>수백만 행</b> 규모가 된다. |
| 설명       | 청크 읽기는 “한 번에 전월 로드” 문제는 피하지만, 최종 concat·집계 단계에서는 여전히 대용량 메모리·디스크가 필요하다.                                           |
| 연관<br>한계 | <b>연산 자원 한계</b> ? 이후 ML은 전량이 아닌 샘플( ML_SAMPLE_ROWS=80_000 )로 학습한다. ETL은 풍부한데 학습은 축소된 대표 표본에 의존한다.                 |

### 3-3. 컬럼 위치 기반 파싱

| 항목       | 내용                                                                            |
|----------|-------------------------------------------------------------------------------|
| 이슈       | <code>_process_chunk</code> 가 <code>iloc[:, 0] ~ iloc[:, 4]</code> 로 컬럼을 읽는다. |
| 설명       | 공공 CSV 스키마가 바뀌면 조용히 잘못 매핑될 수 있다. 현재 파일 형식에 강하게 결합되어 있다.                       |
| 연관<br>한계 | <b>유지보수·이식성 한계</b> ? 데이터 형식 변경 시 ETL 전면 수정이 필요하다.                             |

## 4. 군집화 ( `src/clustering.py` )

### 4-1. DBSCAN `min_samples=1` 과 200m 해석

| 항목       | 내용                                                                                                                                                       |
|----------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | <code>eps=200m</code> , <code>min_samples=1</code> 이면 이론상 인접 대여소가 연쇄적으로 묶여 <b>구역 직경이 200m를 넘는 클러스터</b> 가 생길 수 있다. 리포트상 직경 250m 초과 구역이 다수 존재한다.           |
| 설명       | DBSCAN의 <code>eps</code> 는 “이웃 반경”이지 “클러스터 최대 직경”이 아니다. <code>min_samples=1</code> 은 단일 대여소도 클러스터가 되게 하여, 평균 <b>1.6대여소/구역</b> 처럼 대부분이 사실상 단일 대여소 구역이 된다. |
| 연관<br>한계 | <b>공간 단위 한계</b> ? “약 200m 구역”은 목표이지, 모든 구역이 엄밀히 200m 이내는 아니다. 출발지→구역 매핑( <code>assign_cluster</code> )은 <b>구역 중심과의 거리</b> 로 하며, 200m 밖이면 경고만 출력한다.       |
| 영향       | 구역 ID가 곧 “도보권”이 아니며, 가용성은 인근이 아닌 <b>같은 <code>cluster_id</code>를 공유하는 먼 대여소</b> 통계에 섞일 수 있다.                                                              |

### 4-2. Notebook 지도 시각화의 단순화

| 항목 | 내용                                                                                |
|----|-----------------------------------------------------------------------------------|
| 이슈 | Notebook §3은 대여소 300개 샘플 점만 표시하고, <code>cluster_id</code> 별 색·경계·200m 원은 그리지 않는다. |

| 항목       | 내용                                                             |
|----------|----------------------------------------------------------------|
| 설명       | cluster_diameter_stats 는 코드에 있으나 Notebook EDA 파이프라인에 연결되지 않았다. |
| 연관<br>한계 | 검증 가시성 한계 ? 군집 품질 이슈(직경 이상치)를 Notebook만 보고는 파악하기 어렵다.          |

## 5. 머신러닝 ( src/ml\_models.py , scripts/train\_models.py )

### 5-1. cluster\_id 수치 처리와 선형 회귀 실패

| 항목       | 내용                                                                                                                                                                                     |
|----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | NUM_FEATURES 에 cluster_id 가 포함되고 StandardScaler 로 스케일링된다. 범주형 구역 (1,706개)을 <b>순서 있는 숫자</b> 처럼 다룬다.                                                                                     |
| 설명       | 선형 회귀는 cluster_id 100과 101이 “가까운 구역”처럼 선형 관계를 가정한다. 실제로는 임의 라벨이다. 결과적으로 <b><math>R^2 \approx 0.009</math></b> 수준의 설명력에 그친다.                                                            |
| 연관<br>한계 | <b>모델 가정 한계 ?</b> 선형 회귀는 본 과제에서 <b>베이스라인·대비군</b> 역할에 가깝고, 구역 효과를 제대로 넣으려면 one-hot·target encoding 등이 필요하다. RF는 트리 분할로 우연히 구역을 나누어 <b><math>R^2 \approx 0.44 \sim 0.48</math></b> 을 낸다. |
| 영향       | Notebook에서 “Linear vs RF” 비교 시, 차이는 <b>알고리즘만이 아니라 특성 처리 적합성</b> 에서도 크게 난다.                                                                                                             |

### 5-2. 학습 샘플 80,000행

| 항목       | 내용                                                                                                                                     |
|----------|----------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | train_models.build_sample() 이 ml_train.csv 에서 최대 60만 행 읽은 뒤 <b>8만 행 무작위 샘플</b> 을 저장·학습한다. Notebook도 ml_train_sample.csv 가 있으면 우선 사용한다. |
| 설명       | zone_hour 전체는 약 267만 행이나, ML_MAX_ROWS=200_000 · ML_SAMPLE_ROWS=80_000 로 의도적 축소했다. train_models() 내부에서 또 max_rows 초과 시 sample() 할 수 있다. |
| 연관<br>한계 | <b>통계 대표성 한계 ?</b> 회귀 시간대·구역 조합이 샘플에서 빠지면 테스트·실사용 예측이 불안정해진다. 성능 지표는 “8만 행 기준 hold-out”에 묶인다.                                          |

| 항목 | 내용                                                                                     |
|----|----------------------------------------------------------------------------------------|
| 영향 | 동일 입력에서 Linear 9.3대 vs RF 0.8대처럼 <b>모델 간 예측 편차</b> 가 클 때, 샘플·구역 커버리지 부족이 한 원인이 될 수 있다. |

### 5-3. 제한된 특성 집합

| 항목       | 내용                                                                                                           |
|----------|--------------------------------------------------------------------------------------------------------------|
| 이슈       | 특성은 hour , dow , is_weekend , month , season , cluster_id 뿐이다. qr_slots (거치대 용량), 날씨, 공휴일, 대여소별 이력 등은 미사용이다. |
| 설명       | ETL·stations에 qr_slots 가 로드되나 ml_train 까지 전달되지 않는다.                                                          |
| 연관<br>한계 | <b>예측 변수 한계</b> ? 같은 시각·구역이라도 <b>용량·수요 충격</b> 에 따른 변동은 설명하지 못해 $R^2$ 상한이 낮다(현재 RF도 분산의 약 절반만 설명).            |
| 영향       | “몇 시쯤이나”는 맞을 수 있어도 “그날 그 구역이 특별히 비었는지”는 맞추기 어렵다.                                                             |

### 5-4. 시계열 hold-out과 GridSearch cv=2

| 항목       | 내용                                                                                                                 |
|----------|--------------------------------------------------------------------------------------------------------------------|
| 이슈       | time_split 은 월별 마지막 7일을 test로 두어 <b>미래 누수 방지</b> 의도는 좋다. 다만 GridSearchCV는 cv=2 , RF 기본 n_estimators=50 으로 연산을 줄였다. |
| 설명       | 교차검증 fold가 적으면 하이퍼파라미터 추정 분산이 크다. 튜닝 전·후 차이(MAE 5.17→5.02)는 <b>소폭 개선</b> 에 그친다.                                    |
| 연관<br>한계 | <b>튜닝 신뢰도 한계</b> ? “튜닝으로 성능이 크게 오른다”기보다, RF family 내 미세 조정 수준으로 해석하는 것이 타당하다.                                      |

## 6. 예측·API ( src/predict.py , src/kakao\_map.py )

### 6-1. 목적지·자전거 구간 미연결 (핵심 시나리오 단순화)

| 항목       | 내용                                                                                                                                      |
|----------|-----------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | predict_origin_rental 은 출발지 + 할당 가능 시간(분) + 기준 시각만 받는다.<br>kakao_map.get_duration(..., "bike") 는 구현되어 있으나 예측 파이프라인에서 호출되지 않는다.          |
| 설명       | 흐름: 지오코딩 → 구역·최근접 대여소 → <b>도보 소요</b> → rent_time = ref + walk → ML 가용 예측. 목적지 도착 시각 역산, “집→대여소→목적지” 전체 소요는 없다.                          |
| 연관<br>한계 | <b>문제 정식화 한계</b> ? 과제 제목의 “언제 출발해야 탈 수 있을까”를 ***“할당 시간 안에 대여소에 갈 수 있고, 그때 자전거가 있을 것 같다”**로 근사했다. 목적지 일정과 연동된 출발권장은 <b>현 버전 범위 밖</b> 이다. |
| 영향       | 사용자가 “9시까지 광화문”을 입력할 수 없고, <b>이동 목적·자전거 구간</b> 이 결과에 반영되지 않는다.                                                                          |

### 6-2. 과거 패턴으로 “지금” 시각 예측

| 항목       | 내용                                                                                                                  |
|----------|---------------------------------------------------------------------------------------------------------------------|
| 이슈       | ML은 2024년 3개월로 학습했으나, Notebook §6 기본값은 datetime.now() 기준 날짜·시각이다.                                                   |
| 설명       | _features_for 는 rent_time 의 month·season·hour만 쓰며, <b>연도는 특성에 없다</b> . 2026년 실행 시에도 2024년과 같은 “4월 화요일 8시” 패턴을 적용한다. |
| 연관<br>한계 | <b>시간 일반화 한계</b> ? 코로나 이후 수요 변화, 대여소 증감, 정책 변경은 반영되지 않는 <b>과거 스냅샷 기반 추정</b> 이다.                                     |
| 영향       | 데모는 DEMO_REF_TIME = 2024-04-15 가 학습 분포와 맞지만, 실사용 날짜는 <b>분포 외 extrapolation</b> 에 가깝다.                               |

### 6-3. API vs Demo 소요시간

| 항목 | 내용                                                                                                               |
|----|------------------------------------------------------------------------------------------------------------------|
| 이슈 | Kakao Mobility 실패 시 haversine 직선거리 ÷ 고정 속도(도보 4.5km/h, 자전거 15km/h)로 대체한다. REST API IP 미등록 시 지오코딩도 좌표 Demo로 대체한다. |

| 항목       | 내용                                                                                                                                   |
|----------|--------------------------------------------------------------------------------------------------------------------------------------|
| 설명       | _mobility_duration 은 mode를 구분하지 않고 경로 API 결과만 쓴다. Demo는 곡률·신호·일방통행을 무시한다. API 성공 시에도 출발지가 대여소와 매우 가까우면 <b>도보 0분</b> 처럼 보일 수 있다.      |
| 연관<br>한계 | <b>이동 시간 추정 한계</b> ? timing_feasible , depart_home , rent_time 이 <b>실제 도로 환경과 어긋날</b> 수 있다. 가용성 ML 오차와 별개로 <b>일정 역산 자체가 부정확</b> 해진다. |
| 영향       | API/Demo 모드에 따라 <b>같은 주소도 다른 판정</b> 이 나올 수 있으며, Notebook은 모드를 출력하지만 불확실성 정량화는 하지 않는다.                                                |

## 6-4. 모델 간 예측 불일치와 단일 모델 판정

| 항목       | 내용                                                                                                                |
|----------|-------------------------------------------------------------------------------------------------------------------|
| 이슈       | _predict_all 은 세 모델 예측을 모두 출력하지만, _feasibility_pred 는 <b>FEASIBILITY_MODEL = "RF Tuned" 만</b> 으로 대여 가능 여부를 결정한다.  |
| 설명       | 동일 feature에서 Linear 11.8대 vs RF 0.8대 같은 극단적 차이가 발생할 수 있다. 이는 §5.1 특성 처리·§5.2 샘플 한계와 맞물린다.                         |
| 연관<br>한계 | <b>의사결정 불확실성 한계</b> ? “어느 모델을 믿을 것인가”에 대한 불확실성·양상불·구간 추정이 없다. RF Tuned 선택은 성능 표상 합리적이거나 <b>단일 점 추정의 위험</b> 은 남는다. |
| 영향       | 보고서·Notebook 독자는 숫자 차이를 <b>한계의 증거</b> 로 읽어야 하며, 단일 모델 판정은 보수적·낙관적 오류를 동시에 만들 수 있다.                                |

## 6-5. 가용성 재시도 로직

| 항목       | 내용                                                                       |
|----------|--------------------------------------------------------------------------|
| 이슈       | _retry_until_available 은 예측 대수가 부족하면 rent_time 을 <b>1시간씩 최대 6회</b> 앞당긴다. |
| 설명       | 실제로는 다른 대여소·다른 경로를 고려하지 않고, <b>같은 구역·같은 모델</b> 만 재조회한다.                  |
| 연관<br>한계 | <b>행동 대안 한계</b> ? “조금 일찍 가라”는 단순 휴리스틱이며, 인근 구역 대안·임계값 미만 확률은 제시하지 않는다.   |



## 7. Notebook·스크립트 ( notebooks/ , scripts/ )

### 7-1. EDA·결론 부족

| 항목       | 내용                                                                                                           |
|----------|--------------------------------------------------------------------------------------------------------------|
| 이슈       | Notebook §2는 시간대별 평균 1그래프와 zero rate만 있다. §7 Summary는 외부 문서 링크 한 줄이다.                                        |
| 설명       | generate_notebook.py 가 동일 구조를 재생성한다. 구현 이슈·한계 서술이 Notebook <b>내부에 없다.</b>                                    |
| 연관<br>한계 | <b>분석 보고 한계</b> ? 코드는 돌아가나, “왜 Linear가 실패했는지·RF를 쓰는지·무엇을 믿지 말아야 하는지”가 산출물에 담기지 않는다. 본 report/ 문서가 그 공백을 메운다. |

### 7-2. run\_pipeline.py 리포트 생성 버그

| 항목       | 내용                                                                                                                                             |
|----------|------------------------------------------------------------------------------------------------------------------------------------------------|
| 이슈       | write_cluster_report() f-string에서 CLUSTER_EPS_M 을 참조하나 <b>import하지 않아</b> 해당 함수 실행 시 NameError 가 날 수 있다. (군집화·ETL 본체는 src/clustering 에서 정상 동작) |
| 설명       | 파이프라인 마지막 리포트 작성 단계만 실패할 수 있다. clustering-report.md 는 이전 성공 실행분이 남아 있을 수 있다.                                                                   |
| 연관<br>한계 | <b>운영 신뢰도 한계</b> ? 자동 검증·CI 없이 스크립트 전 구간을 매번 실행 검증하지 않으면, <b>문서와 코드 상태 불일치</b> 가 생긴다.                                                          |

### 7-3. Notebook과 src 이중 유지

| 항목       | 내용                                                                                     |
|----------|----------------------------------------------------------------------------------------|
| 이슈       | 로직은 src 에 두고 Notebook은 호출하지만, generate_notebook.py 로 Notebook을 <b>재생성</b> 하는 구조다.      |
| 설명       | Notebook을 직접 수정하면 generator와 어긋날 수 있다.                                                 |
| 연관<br>한계 | <b>동기화 한계</b> ? 최종 제출물이 Notebook인데, 진실의 원천(source of truth)이 src 와 generator 양쪽으로 나뉜다. |

## 8. 이슈?한계 대응표 (요약)

| #  | 구현 이슈                   | 관련 파일                             | 연관 한계      | 심각도     |
|----|-------------------------|-----------------------------------|------------|---------|
| 1  | 3개월·조인 제외 데이터만 사용       | paths.py , etl.py                 | 시간·공간 커버리지 | 중       |
| 2  | 구역 평균 타킷 vs 최근접 대여소     | etl.py , predict.py               | 공간 해상도     | 중       |
| 3  | DBSCAN 직경 > 200m 구역 존재  | clustering.py                     | 200m 구역 가정 | 중       |
| 4  | cluster_id 수치 스케일링      | ml_models.py                      | 선형 모델 가정   | 높음 (LR) |
| 5  | 8만 행 샘플 학습              | train_models.py , config.py       | 통계 대표성     | 중       |
| 6  | 특성 부족 (용량·날씨 등)         | ml_models.py , etl.py             | 예측 상한      | 중       |
| 7  | 목적지·자전거 leg 미구현         | predict.py , kakao_map.py         | 문제 정식화     | 높음      |
| 8  | 2024 학습 → 현재 날짜 예측      | predict.py , Notebook §6          | 시간 일반화     | 중       |
| 9  | API/Demo 소요시간 차이        | kakao_map.py                      | 이동 시간 추정   | 중       |
| 10 | RF Tuned 단일 판정          | predict.py , config.py            | 의사결정 불확실성  | 중       |
| 11 | Notebook EDA·결론 빈약      | notebooks/ , generate_notebook.py | 분석 보고      | 낮~중     |
| 12 | CLUSTER_EPS_M import 누락 | run_pipeline.py                   | 재현·운영      | 낮 (버그)  |

**심각도:** 예측 신뢰도·과제 스토리 완결성에 미치는 영향 기준 (높음 / 중 / 낮음).

## 9. 결론: 한계를 어떻게 읽을 것인가

본 프로젝트 구현은 공공데이터 ETL → 공간 군집 → 시·공간 회귀 → 지도 API 보조 → Notebook 데모까지의 오프라인 분석 파이프라인으로서 3학년 데이터마닝 과제 요건(군집화, 선형 회귀, Random Forest, 하이퍼파라미터 튜닝, 비교)을 충족한다.

다만 다음을 전제로 결과를 해석해야 한다.

- 1. 예측은 실시간 따름이 API가 아니라, 2024년 일부 월의 과거 시간대별 패턴이다.
- 2. 공간 단위는 구역 평균이며, 사용자가 쓰는 한 대여소와 1:1이 아니다.
- 3. 출발 권장은 “목적지 역산”이 아니라, “기준 시각부터 할당 시간 내 도보로 대여소 도달 + 그때 가용할 것으로 기대”에 가깝다.
- 4. 선형 회귀 성능 저하는 모델 고장이라기보다, 범주형 cluster\_id 처리와 문제 난이도가 겹친 구조적 한계로 보는 것이 맞다.
- 5. RF Tuned를 판정에 쓰는 것은 테스트 지표상 합리적이거나, 모델 간 편차가 큰 입력에서는 불확실성이 크다는 점을 함께 보고해야 한다.

이 전제들을 명시한 상태에서 Notebook 결과는 \*\*\*가능성 탐색·교육용 의사결정 보조\*\*\*로 적절하며, 실제 출발 시각의 단정적 권고로 쓰기에는 §2~§6의 한계가 누적된다.

## 10. 참고: 성능 지표 (구현 산출물 기준)

data/processed/model\_metrics.json (학습 샘플 80,000행, time hold-out):

| 모델                | MAE  | RMSE | R <sup>2</sup> |
|-------------------|------|------|----------------|
| Linear Regression | 7.32 | 9.79 | 0.009          |
| Random Forest     | 5.17 | 7.38 | 0.436          |
| RF Tuned          | 5.02 | 7.12 | 0.475          |

위 수치는 §5의 한계(샘플·특성·cluster\_id 처리) 안에서 측정된 값이며, 전체 267만 행·개선된 특성 공학과는 다를 수 있다.

본 문서는 UTF-8로 저장되었습니다.